




数值分析(5)

Numerical Analysis

计算机系 软件所 喻文健

第五章 矩阵特征值计算

- 矩阵特征值与特征向量的计算：
数值线性代数、矩阵计算的重要内容

LINPACK → LAPACK

- 本章内容


- 基本概念与特征值的分布
- 幂法与反幂法
- 矩阵的正交三角化, **QR**分解
- 计算所有特征值的**QR**迭代算法
- 矩阵的奇异值分解



Taken in 1979



Jack Dongarra获**2021年图灵奖**主要源于其在数值算法和库方面的开创性贡献，正是他的研究使高性能计算软件在四十多年里与硬件的指数级提升保持同步。



矩阵特征值有关概念

基本概念

- 矩阵 A 的**特征值与特征向量**, ($A \in \mathbb{R}^{n \times n}$)

$$Ax = \lambda x, \quad x \neq 0$$

若均为实数, 限定
特征向量空间为 $\mathbb{R}^n$

- 特征值 λ 是**特征方程**的根, 复数域内有 n 个(含重根) 否则在复数域上讨论

$$\det(\lambda I - A) = \begin{vmatrix} \lambda - a_{11} & -a_{12} & \cdots & -a_{1n} \\ -a_{21} & \lambda - a_{22} & \cdots & -a_{2n} \\ \cdots & \cdots & \cdots & \cdots \\ -a_{n1} & -a_{n2} & \cdots & \lambda - a_{nn} \end{vmatrix} = 0$$

谱半径 $\rho(A)$

- **特征值谱**: $\lambda(A)$
- 特征值 λ 对应的**特征向量**是方程 $(\lambda I - A)x = 0$ 的**非零解**
- 特征向量不唯一, 构成**特征子空间** $\mathbb{R}^n$ or $\mathbb{C}^n$
- $A \in \mathbb{R}^{n \times n}$, (1)特征值不一定是实数; (2)实特征值一定对应**实特征向量**; (3)非实特征值的共轭也是特征值, 其对应的**特征向量一定不是实向量**

特征值的有关性质

$$Ax = \lambda x, \quad x \neq 0$$

- 非奇异矩阵的特征值 $\neq 0$; 0一定是奇异矩阵的特征值
- Th5.2 ■ $\lambda(A) = \lambda(A^T)$ $\det(\lambda I - A) = \det((\lambda I - A)^T)$
- Th5.3 ■ 若 A 为对角阵或上(下)三角阵, 则其特征值为其对角元
- Th5.4 ■ 若 A 为分块对角阵或分块上(下)三角阵(对角块为方阵), 则
$$\lambda(A) = \bigcup_{j=1}^b \lambda(A_{jj})$$
$$A = \begin{bmatrix} A_{11} & A_{12} & \cdots & A_{1b} \\ & A_{22} & \cdots & A_{2b} \\ & & \ddots & \vdots \\ & & & A_{bb} \end{bmatrix}$$
- Th5.5 ■ 相似矩阵的特征值相等
$$B = V^{-1}AV$$
- Th5.9 ■ 矩阵运算结果的特征值: 设 λ_j 为 A 的特征值, 则
$$\lambda(cA) = \{c\lambda_j\}; \quad \lambda(A + cI) = \{\lambda_j + c\}; \quad \lambda(A^k) = \{\lambda_j^k\}; \quad \lambda(A^{-1}) = \{\lambda_j^{-1}\}$$
- **定义5.2** 设 $A \in \mathbb{R}^{n \times n}$ 有 m 个 ($m \leq n$) 不同的特征值 $\tilde{\lambda}_1, \dots, \tilde{\lambda}_m$, 若 $\tilde{\lambda}_j$ 是特征方程的 n_j 重根, 则称 n_j 为 $\tilde{\lambda}_j$ 的代数重数, 而 $\tilde{\lambda}_j$ 对应特征子空间的维数是其几何重数.

特征值的有关性质

- 设 n 阶方阵 A 的 m 个不同的特征值为 $\tilde{\lambda}_1, \dots, \tilde{\lambda}_m$, $\tilde{\lambda}_j$ 的代数重数为 n_j , 几何重数为 k_j , 则

Th5.6 $\square \sum_j n_j = n; \quad n_j \geq k_j, \quad \forall j$

- $\square$ 不同特征值的特征向量线性无关, 所有特征子空间的 $\sum_{j=1}^m k_j$ 个基形成一组线性无关向量 (可能少于 n 个)

定义5.3 $\square$ 若 $\forall j, n_j = k_j$, 这种矩阵 A 为**非亏损阵**, 否则为**亏损阵**.

非亏损阵有 n 个特征向量构成全空间的基 ($\mathbb{R}^n$ or $\mathbb{C}^n$)

Th5.7 ■ A 为非亏损阵 $\Leftrightarrow \exists X$ 与对角阵 Λ 使 $X^{-1}AX = \Lambda$ (即**特征值分解**)

Th3.3 ■ 实对称阵为非亏损阵, 且特征值为实数、可**正交**对角化

■ **Th5.8**(Jordan分解): $A = XJX^{-1}$, $J = \begin{bmatrix} J_1 & & \\ & \ddots & \\ & & J_p \end{bmatrix}$, $J_s = \begin{bmatrix} \lambda_s & 1 & & \\ & \lambda_s & \ddots & \\ & & \ddots & 1 \\ & & & \lambda_s \end{bmatrix}$
 $p = \sum k_j$, k_j 为特征值 $\tilde{\lambda}_j$ 的几何重数;
 $\tilde{\lambda}_j$ 对应 k_j 个约当块, 其阶数之和 = n_j (约当标准型)

特征值的分布

■ 为何关心特征值分布？

□ 迭代法 $\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{f}$ 的收敛性, 看 $\rho(\mathbf{B}) = \max_j |\lambda_j(\mathbf{B})|$

□ 矩阵的2-条件数: $\text{cond}(\mathbf{A})_2 = \sqrt{\frac{\lambda_{\max}(\mathbf{A}^T \mathbf{A})}{\lambda_{\min}(\mathbf{A}^T \mathbf{A})}}$,

■ $\rho(\mathbf{A}) \leq \|\mathbf{A}\|_v$

■ **定义5.4** $\mathbf{A} \in \mathbb{C}^{n \times n}$, 设 $r_k = \sum_{j=1, j \neq k}^n |a_{kj}|$, 在复平面上以 a_{kk} 为圆心、 r_k 为半径的圆, 称为 $\mathbf{A}$ 的 **Gerschgorin 圆盘**

■ **Th5.10** (圆盘定理)


? □ $\mathbf{A}$ 的特征值必在 n 个圆盘的并集上

□ 若 n 个圆盘中有 m 个连通, 且与其


他分离, 则这 m 个圆盘中恰好含 m 个特征值

设 λ 为任一特征值


$\mathbf{A}\mathbf{x} = \lambda\mathbf{x}$, 设 $\mathbf{x}$ 的第 k 个分量最大 $\Rightarrow (\lambda - a_{kk})x_k = \sum_{j \neq k} a_{kj}x_j \Rightarrow |\lambda - a_{kk}| \leq \sum_{j \neq k} |a_{kj}|$




圆盘定理的应用



- **Th5.11** 对角元均为正的实矩阵 A , 1)若 A 严格对角占优, 则 $\text{Re}(\lambda) > 0$; 2)若 A 为对角占优的对称阵, 则...
SDD $\rightarrow$ 对称正定
- **例5.3:** 估计矩阵 $A = \begin{bmatrix} 4 & 1 & 0 \\ 1 & 0 & -1 \\ 1 & 1 & -4 \end{bmatrix}$ 的特征值分布 Java演示5.2
- 直接应用圆盘定理, D_1 与其他两个分离, 必含一个实特征值
- 再对 A^T 应用圆盘定理, D'_3 与其他圆盘分离, 必含一实特征值
- $\lambda_1 \in [3, 5], \lambda_3 \in [-5, -3], \lambda_2 \in [-2, 2]$
- 准确特征值为: 4.2030, -3.7601, -0.4429
- 还可先做简单的相似变换, 再估计分布, 见课本例5.4





幂法与反幂法

计算模最大的特征值、特征向量

- **定义5.5** 模最大的特征值称为**主特征值**, 也叫“第一特征值”, 它对应的特征向量称为**主特征向量**
- 主特征值可能**不唯一**, 例如 $5, -5, 3 + 4i, 3 - 4i$ 的模都是5
- **幂法**(power iteration): 随机取一非零向量 v_0 , 计算 $v_k = Av_{k-1}, (k = 1, 2, \dots)$, 得到向量序列 $\{v_k\}, \dots$
- 例子:
$$A = \begin{bmatrix} 5 & -1 & -1 \\ 3 & 1 & -1 \\ 4 & -2 & 0 \end{bmatrix}$$
(课本例5.2, 其主特征值为3)
- 取 $v_0 = [1, 0, 0]^T$, 用Matlab算向量序列 $\{v_k\}$
- 看出: 相邻两个 v_k 逐渐呈倍数关系, 倍数为**3.414**
- v_k 趋近于**3.414**对应的特征值向量

幂法

- 幂法是否总能计算矩阵的主特征值？
- **定理5.12** 若矩阵 A 有**唯一**的主特征值 λ_1 ($\neq 0$), 取**随机非零**向量 $\mathbf{v}_0$, 计算 $\mathbf{v}_k = A\mathbf{v}_{k-1}, (k = 1, 2, \dots)$, 则:

$$\mathbf{v}_k \xrightarrow[k \rightarrow \infty]{} \lambda_1 \text{ 的特征向量}$$

- **证明:** 考虑 A 为非亏损阵的情况

注意: 需要 $\mathbf{v}_0$ 对应 $\alpha_1 \neq 0$

设 A 的线性无关的特征向量为 $\hat{\mathbf{x}}_1, \dots, \hat{\mathbf{x}}_n$, $\mathbf{v}_0 = \alpha_1 \hat{\mathbf{x}}_1 + \dots + \alpha_n \hat{\mathbf{x}}_n$

$$\mathbf{v}_k = A^k \mathbf{v}_0 = \alpha_1 \lambda_1^k \hat{\mathbf{x}}_1 + \dots + \alpha_n \lambda_n^k \hat{\mathbf{x}}_n = \lambda_1^k \left[\sum_{j=1}^s \alpha_j \hat{\mathbf{x}}_j + \sum_{j=s+1}^n \alpha_j \left(\frac{\lambda_j}{\lambda_1} \right)^k \hat{\mathbf{x}}_j \right]$$

$\therefore \mathbf{v}_k$ 趋向于某主特征向量的倍数 (设 λ_1 为 s 重特征值)

模 <1

而且, 若 l 为 $\mathbf{v}_k$ 的绝对值最大元素, 则 $\lim_{k \rightarrow \infty} \frac{(\mathbf{v}_{k+1})_l}{(\mathbf{v}_k)_l} = \lambda_1$

幂法

$$\boldsymbol{v}_k = A\boldsymbol{v}_{k-1}$$

■ 关于幂法的说明

- A 为亏损矩阵的情况, 用矩阵的Jordan分解进行证明
- $\{\boldsymbol{v}_k\}$ 相邻项的第 j 分量比值 $\rightarrow$ 主特征值, 选最大分量 $\neq 0$
- 在实际应用时随机选取 $\boldsymbol{v}_0$, 避免出现特殊情况

■ 幂法的问题

$\boldsymbol{v}_k \approx \lambda_1^k \boldsymbol{x}_1$, k 很大时, 可能出现上溢或下溢

$$\boldsymbol{v}_k = \lambda_1^k \left[\sum_{j=1}^s \alpha_j \hat{\boldsymbol{x}}_j + \sum_{j=s+1}^n \alpha_j \left(\frac{\lambda_j}{\lambda_1} \right)^k \hat{\boldsymbol{x}}_j \right], \quad \text{收敛速度主要取决于} \left| \frac{\tilde{\lambda}_2}{\lambda_1} \right|$$

$\tilde{\lambda}_2$ 为大小仅次于 λ_1 的特征值

■ 实用的幂法: 用规格化向量的技术防止溢出

■ 规格化向量的技术可以通过除以向量范数实现

注意: 课本上使用绝对值最大分量 $\overline{\max}(\boldsymbol{v})$ 的方法由于它不连续, 有错!

实用的幂法

(修订版)

■ 算法5.1: 计算主特征值 λ_1 和主特征向量 x_1 的实用幂法

输入: A ; 输出: x_1, λ_1 .

u : = 随机向量;

While 不满足判停准则 do

v : = Au ;

l 为 u 的绝对值最大的分量的下标;

λ_1 : = v_l / u_l ; {主特征值近似值}

u : = $v / \|v\|_\infty$; {规格化}

End

x_1 : = u . {规格化的主特征向量}

每步的主要计算
是算一次矩阵与
向量乘法

对稀疏阵 A 是
很友好的

规格化改为除以范数

■ 可用相邻两步得到的 λ_1 之差作判停准则

■ 规格化保证数值不上/下溢


迭代步数少时可不作规格化

加速幂法的收敛

■ 原点位移技术

- $B = A - sI$ 的特征值为 A 的特征值 $-s$
对 B 应用幂法可能加快收敛

- 如图中 A 的特征值分布, $\left| \frac{\tilde{\lambda}_2 - s}{\lambda_1 - s} \right| < \left| \frac{\tilde{\lambda}_2}{\lambda_1} \right|$, 更快收敛



■ 瑞利商(Rayleigh quotient)加速

- 实对称阵 A 的瑞利商: $R(x) = \frac{\langle Ax, x \rangle}{\langle x, x \rangle} = \frac{x^T Ax}{x^T x}$

Th5.15 □ 对实对称阵 A , $\lambda_n \leq R(x) \leq \lambda_1$, λ_1 (λ_n) 为最大(最小)特征值;
若 x 为相应特征向量, 不等号变等号

Th5.16 □ 若实对称阵的主特征值唯一, 则幂法中规格化向量 u_k 满足

$$R(u_k) = \lambda_1 + O\left(\left(\tilde{\lambda}_2/\lambda_1\right)^{2k}\right) \quad \text{注意: 幂法, } \sim \lambda_1 + O\left(\left(\tilde{\lambda}_2/\lambda_1\right)^k\right)$$

- 在幂法中, 用计算 $R(u_k)$ 代替计算向量分量的比值 见课本

反幂法

- A^{-1} 与 A 的特征值互为倒数, 对 A^{-1} 应用幂法得按模最小特征值

算法5.2 算按模最小特征值/特征向量的反幂法 (修订版)

输入: A ; 输出: x_n, λ_n .

u : = 随机向量;

While 不满足判停准则 do

v : = $A^{-1}u$; {求解线性方程组}

l 为 v 的绝对值最大的分量的下标;

λ_n : = u_l/v_l ; {模最小特征值的近似值}

u : = $v/\|v\|_\infty$; {规格化}

End

x_n : = u . {规格化的特征向量}

求解线性方程组, 计算量可能比幂法大很多

- 适用范围: A 按模最小的特征值唯一
- 与原点位移技术结合: 若已知某个特征值 $\lambda_j \approx p$, 则 $\lambda_j - p$ 是 $B = A - pI$ 按模最小的特征值, 对 B 使用反幂法

小结

■ 实用幂法可能失败的情况

- 矩阵 A 的主特征值不唯一, 例如某个实矩阵, 其模最大的特征值有不只一个数 (相反数、成对虚数)
- 反幂法的情况类似

■ 说明几点

- 按幂法迭代计算, 若前后两次迭代向量成比例, 则它一定就是特征向量, 也相应求出特征值
- 反幂法与位移技术结合, 是很重要的技术
- 加速幂法的方法还有Aitken外推等算法

思考: $V_k = AV_{k-1}$, $k=1, 2, \dots$ V_k 是有多列的矩阵会怎样?

应用实例: PageRank™的计算

■ Google网络搜索


- PageRank技术是其创立初的**关键创新**之一
- 搜索分两步: **找到匹配关键词的网址, 排序显示**
- L. Page和S. Brin于1998年提出PageRank算法
- 给出网页信息可靠/重要性的指标(Rank)
- 怎样的网页Rank高? 被推荐, 被**链接**到

■ 数学模型

- n : 网页的总数, $G = (g_{ij})_{n \times n}$: 网页链接矩阵

- 若网页 j 链接到网页 i , 则
 $g_{ij} = 1$, 否则 $g_{ij} = 0$

$$G = \begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 1 & 1 & 0 \end{bmatrix}$$



大规模、非对
称、稀疏阵

应用实例: PageRank™的计算

■ 数学模型 (续)

- G 的列元素之和 $c_j = \sum_i g_{ij}$, 等于网页 j 的“出度”
- 访问网页的Markov过程, 到达网页的极限概率定义为它的Rank (按概率 p 沿链接跳, 按概率 $1-p$ 随便跳)
- 设当前在网页 j 、下一步到网页 i 的条件概率为 a_{ij} :
i在 j 的链接上: $p \cdot 1/c_j + (1-p) \cdot 1/n$ 乘 g_{ij}
i不在 j 的链接上: $(1-p) \cdot 1/n$ 乘 $(1-g_{ij})$
$$a_{ij} = \frac{p g_{ij}}{c_j} + \frac{1-p}{n}$$
- a_{ij} 组成转移概率矩阵 A : $A = pGD + \frac{1-p}{n} \mathbf{e}\mathbf{e}^T$ (若不存在 $c_j=0$ 情况)
- 若有 $c_j = 0$ 呢? $a_{ij} = 1/n$, 修改 A 相应的列
- 设 $\mathbf{x}^{(k)}$ 为第 k 次跳转后在各个网页的概率,
则 $\mathbf{x}^{(k+1)} = A\mathbf{x}^{(k)}$ 为再跳一次后在各网页的概率

应用实例: PageRank™的计算

■ 数学模型(续)

- Page Rank: 随机"冲浪"过程访问网页的**极限**概率

$$x^{(k+1)} = Ax^{(k)} \quad \lim_{k \rightarrow \infty} x^{(k)} = ? \quad \text{它存在吗?}$$

■ 上述算法(幂法)的理论分析

- 数学本质: 求**1**对应的特征向量 x

$$\begin{cases} Ax = x \\ \sum_{i=1}^n x_i = 1 \end{cases}$$

- 矩阵 A 的特点: $a_{ij} > 0$, 每列元素之和均为**1**


- $\rho(A) \leq 1$; $A^T e = e \xrightarrow{\text{绿色箭头}} 1$ 是主特征值


- 可放心地用幂法

唯一主特征值

- Page Rank反映超链接结构, 隔一段时间需重新计算

- 计算中不需对 $x^{(k)}$ 规格化; 实际编程时不形成矩阵 A






矩阵的QR分解

Householder变换



■ 矩阵的正交三角化

- 高斯消去过程
- 可用正交阵来乘吗?
- 是矩阵特征值计算、曲线拟合等解法的基础



■ Householder矩阵

- **定义5.8** $w \in \mathbb{R}^n$ 且 $w^T w = 1$, 称 $H(w) = I - 2ww^T$ 为 Householder矩阵 (初等反射阵)

- $H(w) = H(-w)$
- H 为对称阵、正交阵 $H =$
- Hx 实现 Householder变换

$$H = \begin{bmatrix} 1-2w_1^2 & -2w_1w_2 & \cdots & -2w_1w_n \\ -2w_2w_1 & 1-2w_2^2 & \cdots & -2w_2w_n \\ \vdots & \vdots & \cdots & \vdots \\ -2w_nw_1 & -2w_nw_2 & \cdots & 1-2w_n^2 \end{bmatrix}$$

Householder变换

■ Householder变换的几何意义


□ $H(w)$: 设超平面 S 的法向为 w $\xrightarrow{n-1\text{维子空间}}$

$$Hx = (I - 2ww^T)x = x - 2ww^Tx$$

$$ww^Tx = (w^Tx)w = v \xrightarrow{\text{绿色箭头}} Hx = x - 2v$$

□ Hx 为 x 关于超平面 S 的镜像 (初等反射变换)

□ Hx 与 x 的2-范数相等, 属于正交变换



■ **Th5.18** 设 $x, y \in \mathbb{R}^n, x \neq y, \|x\|_2 = \|y\|_2$, 则存在Householder矩阵 H , 使 $Hx = y$

■ 几何的启示: $v = x - y, w = v/\|v\|_2$, 构造矩阵 H

■ **Th5.19** 可将定理5.18中的 y 设为 $\begin{bmatrix} \pm\|x\|_2 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$ 取 $y = -\sigma e_1, \sigma = \text{sign}(x_1)\|x\|_2$ 较好

→ $v = x + \sigma e_1$
 这样就用正交变换实现了消去变换!

Householder变换

$$\mathbf{x} \xrightarrow{H} -\sigma \mathbf{e}_1 \quad \begin{bmatrix} * \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$
$$\sigma = \text{sign}(x_1) \|\mathbf{x}\|_2$$

■ 用正交变换实现消去操作

- 对向量做Householder变换, 结果 $-\sigma \mathbf{e}_1$ 中的负号是为了数值稳定
- 例: 确定一个Householder变换, 对向量实现消去操作

$$\mathbf{a} = \begin{bmatrix} 2 \\ 1 \\ 2 \end{bmatrix} \longrightarrow \begin{bmatrix} * \\ 0 \\ 0 \end{bmatrix}$$

$$\text{解: } \sigma = \text{sign}(a_1) \|\mathbf{a}\|_2 = 3, \text{ 构造 } \mathbf{v} = \mathbf{a} + \sigma \mathbf{e}_1 = \begin{bmatrix} 2 \\ 1 \\ 2 \end{bmatrix} + \begin{bmatrix} 3 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 5 \\ 1 \\ 2 \end{bmatrix}$$

取 $\mathbf{w} = \mathbf{v} / \|\mathbf{v}\|_2$, 则实现变换的矩阵为 $H = I - 2\mathbf{w}\mathbf{w}^T$

$$\text{验证: } H\mathbf{a} = \mathbf{a} - 2(\mathbf{w}^T \mathbf{a})\mathbf{w} = \mathbf{a} - 2 \frac{\mathbf{v}^T \mathbf{a}}{\mathbf{v}^T \mathbf{v}} \mathbf{v} = \begin{bmatrix} 2 \\ 1 \\ 2 \end{bmatrix} - 2 \times \frac{15}{30} \times \begin{bmatrix} 5 \\ 1 \\ 2 \end{bmatrix} = \begin{bmatrix} -3 \\ 0 \\ 0 \end{bmatrix}$$

很重要! 用 $\mathbf{v}$ 或 $\mathbf{w}$ 表示矩阵 H , 计算 $H\mathbf{x}$ 时只算向量内积


矩阵的QR分解

■ 用Householder变换实现正交三角化？


□ $H_k \cdots H_2 H_1 A = R$

□ $A \in \mathbb{R}^{m \times n}$ 不一定是方阵，
上三角阵 R 也同样

$m > n$ 的情况:



$m < n$ 的情况呢？



□ $A = H_1 H_2 \cdots H_k R = QR$, 其中 Q 为正交阵, 称为**QR分解**

□ 其他正交三角化手段: **Givens旋转变换 ...**

Th5.20 对任意实矩阵 A , 一定存在QR分解; 若 A 为非奇异方阵, 且要求 R 的对角元都 >0 , 此分解唯一.

用反证法
证明唯一性

矩阵的QR分解

■ 怎么实现: $H_k \cdots H_2 H_1 A = R$?

□ 设 $A \in \mathbb{R}^{m \times n}$, $m \geq n$, $A = [a_1, a_2, \dots, a_n]$, 其中 a_j 为 m 维向量

构造 m 阶反射阵 H_1

消 A 的第1列:

$$A^{(2)} = H_1 A = \begin{bmatrix} -\sigma_1 & a_{12}^{(2)} & \cdots & a_{1n}^{(2)} \\ 0 & a_{22}^{(2)} & \cdots & a_{2n}^{(2)} \\ \vdots & \vdots & & \vdots \\ 0 & a_{m2}^{(2)} & \cdots & a_{mn}^{(2)} \end{bmatrix} = \begin{bmatrix} -\sigma_1 & | & & | \\ 0 & H_1 a_2 & \cdots & H_1 a_n \\ \vdots & | & & | \\ 0 & | & & | \end{bmatrix}$$

用 H_2 实现 $A^{(2)}$ 第2列的消元, 同时不影响第1列

$$\text{令 } H_2 = \begin{bmatrix} 1 & \mathbf{0}^T \\ \mathbf{0} & H'_2 \end{bmatrix} \quad H_2 A^{(2)} = \begin{bmatrix} -\sigma_1 & r_1^T \\ \mathbf{0} & H'_2 A'^{(2)} \end{bmatrix} = \begin{bmatrix} -\sigma_1 & r_1^T \\ 0 & -\sigma_2 & | & \\ 0 & 0 & H'_2 a_2'^{(2)} & \cdots & H'_2 a_{n-1}'^{(2)} \\ \vdots & \vdots & | & & | \\ 0 & 0 & | & & | \end{bmatrix}$$

记 $A^{(2)} = \begin{bmatrix} -\sigma_1 & r_1^T \\ \mathbf{0} & A'^{(2)} \end{bmatrix}$ 构造反射阵 H'_2

H_2 也是Householder阵(其向量 v 的第一个分量为0). 后续 H_j 可类似构造

算法5.3: 基于Householder变换的矩阵正交三角化 (设 $m \geq n$)

输入: $A = [a_1, a_2, \dots, a_n]$; 输出: $A; v_1, v_2, \dots, v_n$.

For $k=1, 2, \dots, n$

$\sigma_k := \text{sign}(a_{kk}) \sqrt{\sum_{j=k}^m a_{jk}^2}$; {下三角部分第 k 列的2-范数}

If $\sigma_k = a_{kk}$ then {第 k 列对角线下方已经全为0}

Continue with next k ;

End

$v_k := [0, \dots, 0, a_{kk}, \dots, a_{mk}]^T + \sigma_k e_k$; {构造 H_k 的向量}

$\beta_k := v_k^T v_k$;

For $j=k, k+1, \dots, n$ {对剩余各列作Householder变换}

$\gamma_j := v_k^T a_j$;

$a_j := a_j - (2\gamma_j/\beta_k)v_k$; { $H_k a_j^{(k)} = a_j^{(k)} - 2(v_k^T a_j^{(k)}/v_k^T v_k)v_k$ }

End

End

Matlab: $[Q,R] = \text{qr}(A)$; 近十种格式!
 $R = \text{qr}(A)$


- 算法执行完, A 变成 R , 得到构造 $H_1, H_2, \dots, H_k$ 所需的 v 向量
- 总乘法次数: $(2n+1) \cdot m + (2n-1) \cdot m + \dots + 3m \approx mn^2$ 可减少为 $mn^2 - n^3/3$
- 没有生成 Q 矩阵. 如果生成, 则计算量为 $O(mn^2)$

Givens旋转变换

■ 二维平面旋转变换

- 将向量 x 顺时针旋转 θ 角度后得到 y

$$y = \begin{bmatrix} \cos\theta & \sin\theta \\ -\sin\theta & \cos\theta \end{bmatrix} x$$



- **定义**二阶Givens矩阵为: $G = \begin{bmatrix} c & s \\ -s & c \end{bmatrix}$, 其中 $c = \cos\theta$, $s = \sin\theta$

- G 显然是 2×2 的正交阵, 实施平面旋转(称为**Givens旋转**)

- 实现消去操作: 选 c 和 s 值可使 $G \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} \alpha \\ 0 \end{bmatrix}$, $c = \frac{x_1}{\alpha}$, $s = \frac{x_2}{\alpha}$

■ n阶Givens旋转阵

将2阶Givens阵
嵌入n阶单位阵:

- G 仍是正交阵

$$\begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & c & 0 & s & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & -s & 0 & c & 0 \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{bmatrix} = \begin{bmatrix} x_1 \\ \alpha \\ x_3 \\ 0 \\ x_5 \end{bmatrix}$$

$$c = \frac{x_1}{\alpha}$$

$$s = \frac{x_4}{\alpha}$$

Givens旋转变换

■ 例: 用Givens旋转实现消去操作

解: 先针对第1, 3分量构造二阶旋转矩阵,


$$a = \begin{bmatrix} 2 \\ 0 \\ 1 \\ 2 \end{bmatrix} \xrightarrow{\text{green arrow}} \begin{bmatrix} * \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

$$G'_1 = \begin{bmatrix} c_1 & s_1 \\ -s_1 & c_1 \end{bmatrix} \quad c_1 = \frac{2}{\sqrt{2^2 + 1}} = 2/\sqrt{5}, \quad s_1 = 1/\sqrt{5}$$

$$\text{则: } G_1 a = \begin{bmatrix} c_1 & 0 & s_1 & 0 \\ 0 & 1 & 0 & 0 \\ -s_1 & 0 & c_1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 2 \\ 0 \\ 1 \\ 2 \end{bmatrix} = \begin{bmatrix} \sqrt{5} \\ 0 \\ 0 \\ 2 \end{bmatrix} \quad \text{接着对第1, 4分量旋转}$$

$$\text{求出 } c_2 = \sqrt{5}/3, s_2 = 2/3, \quad G_2 G_1 a = \begin{bmatrix} c_2 & 0 & 0 & s_2 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ -s_2 & 0 & 0 & c_2 \end{bmatrix} \begin{bmatrix} \sqrt{5} \\ 0 \\ 0 \\ 2 \end{bmatrix} = \begin{bmatrix} 3 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

- 每个Givens旋转用参数c, s刻画
- 每次旋转仅影响向量两个元素, 仅影响矩阵的两行
- 也可实现矩阵的QR分解, 适合于稀疏矩阵



QR迭代算法

计算矩阵的所有特征值

■ 两个问题

□ 什么样的矩阵易于求所有特征值?

$$X^{-1}AX$$

□ 对矩阵做怎样的变换能保持特征值不变?

$$Q^T A Q$$


■ 思路：用正交相似变换化矩阵为三角阵或分块三角阵

■ 收缩技术

□ 若已知 A 的一个特征向量 x (比如通过幂法/反幂法)

□ 用正交变换将 x 消去: $Hx = \sigma e_1$, 则 e_1 是 HAH^T 的特征向量

$$HAH^T e_1 = HA \left(\frac{1}{\sigma} x \right) = \frac{1}{\sigma} HAx = \frac{1}{\sigma} H\lambda x = \frac{\lambda}{\sigma} (\sigma e_1) = \lambda e_1$$


$$HAH^T = \begin{bmatrix} \lambda & r_1^T \\ 0 & A_1 \end{bmatrix}$$

问题变小!

计算矩阵的所有特征值

- 收缩技术的例子: 已知 $A = \begin{bmatrix} 3 & -1 & 1 \\ 2 & 0 & 1 \\ 1 & -1 & 2 \end{bmatrix}$ 的一个特征值为

$\lambda_1 = 2$, 对应特征向量为 $x_1 = [1, 1, 0]^T$, 求其他特征值

解: 用Householder变换对 x_1 消去, 相应的 $\sigma = \sqrt{2} = 1.4142$

构造矩阵 H 的 v 向量为: $v = x_1 + \sigma e_1 = \begin{bmatrix} 2.4142 \\ 1 \\ 0 \end{bmatrix}$

$$\Rightarrow H = \begin{bmatrix} -0.7072 & -0.7072 & 0 \\ -0.7072 & 0.7072 & 0 \\ 0 & 0 & 1 \end{bmatrix}, HAH^T = \begin{bmatrix} 2 & 3 & -1.4142 \\ 0 & 1 & 0 \\ 0 & -1.4142 & 2 \end{bmatrix}$$

易知 A_1 的特征值为 1, 2, 得到 A 的所有特征值

□ 不形成 H 计算 HAH^T : 先算 $B = HA^T$, 再 $HAH^T = HB^T$

用收缩技术+幂法效率不高, 而且会误差累积, 使结果不准。

QR迭代算法

1959~1961, John G.F. Francis和
Vera N. Kublanovskaya各自发明

■ 理论基础

- **Th5.21**(实Schur分解): $\forall A \in \mathbb{R}^{n \times n}$, $\exists$ 正交阵 Q 使 $Q^T A Q = S$, S 为拟上三角阵
- 拟上三角阵即实Schur型: 对角块为1阶或2阶的分块上三角阵
2阶对角块的特征值是 A 的两个共轭复特征值
- 思路: 用一系列正交相似变换 $B = Q^T A Q$, 逐渐将 A 化为上三角或对角块阶数 ≤ 2 的分块上三角矩阵

■ QR算法 (“二十世纪十大算法”之一)

(由子空间迭代法推导)

$$\begin{cases} \text{对 } A_k \text{ 做QR分解: } A_k = Q_k R_k \\ A_{k+1} = R_k Q_k, (k = 0, 1, \dots) \end{cases} \quad \text{生成正交相似矩阵序列 } \{A_k\}$$

QR迭代算法

基本上是幂法收敛条件的推广
(否则, 对角块维数可能 >2)



■ Th5.22: 收敛定理

- 若矩阵 A 的等模的特征值为实重特征值或复共轭特征值, $\dots$, 则QR迭代所得矩阵序列 $\{A_k\}$ 基本收敛于拟上三角阵

“基本收敛”

$$\begin{bmatrix} \times & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & 0 & 0 & \times \end{bmatrix}$$

算法5.4: 计算矩阵特征值的QR算法

输入: A ; 输出: $\lambda_1, \dots, \lambda_n$.

While A 不是拟上三角阵 **do**

 计算 A 的QR分解, 得到矩阵 Q 和 R ;

$A := RQ$;

End

根据 A 的对角块求特征值 $\lambda_1, \dots, \lambda_n$.

课本上的例5.13

正交相似变换保对称性:
若 A 对称, 则 $Q^T A Q$ 也对称

对实对称阵做QR迭代,
若满足Th5.22条件, 则
极限为对角阵

实用的QR算法

■ QR算法的不足之处

- 每步迭代的计算量很大 将矩阵化简为上Hessenberg阵
- 可能不收敛, 或收敛很慢 带原点位移的QR迭代

■ 如果矩阵是上Hessenberg型

$$\begin{bmatrix} \times & \times & \times & \times \\ \times & \times & \times & \times \\ & \times & \times & \times \\ & & \times & \times \end{bmatrix}$$

- 对它执行QR迭代算法, 其中QR分解应用Givens旋转, 每步计算由 $O(n^3)$ 降为 $O(n^2)$

设 $G_1, G_2, \dots, G_{n-1}$ 为Givens旋转阵, A_k 为上Hessenberg阵

$$G_{n-1} \cdots G_2 G_1 A_k = R_k \Rightarrow Q_k = (G_{n-1} \cdots G_2 G_1)^T$$

$$\begin{aligned} A_{k+1} &= R_k Q_k = G_{n-1} \cdots G_2 G_1 A_k (G_{n-1} \cdots G_2 G_1)^T \\ &= G_{n-1} \cdots G_2 G_1 A_k G_1^T G_2^T \cdots G_{n-1}^T \end{aligned}$$

思考: 证明
 A_{k+1} 仍是上
Hessenberg阵

实用的QR算法

- 将A正交相似约化为上Hessenberg

- 用Householder变换

$$Q^T A Q$$

$$\begin{bmatrix} \times & \times & \times & \times & \times \\ \times & \times & \times & \times & \times \\ \times & \times & \times & \times & \times \\ \times & \times & \times & \times & \times \end{bmatrix} \rightarrow \begin{bmatrix} \times & \times & \times & \times & \times \\ \times & \times & \times & \times & \times \\ & \times & \times & \times & \times \\ & & \times & \times & \times \\ & & & \times & \times \end{bmatrix}$$

$$A = \begin{bmatrix} a_{11} & \mathbf{r}_1^T \\ \mathbf{c}_1 & A_{22}^{(1)} \end{bmatrix} \xrightarrow{H_1 = \begin{bmatrix} 1 & \mathbf{0}^T \\ \mathbf{0} & H'_1 \end{bmatrix}} H_1 A = \begin{bmatrix} a_{11} & \mathbf{r}_1^T \\ \sigma_1 \mathbf{e}_1 & H'_1 A_{22}^{(1)} \end{bmatrix} \rightarrow H_1 A H_1 = \begin{bmatrix} a_{11} & \mathbf{r}_1^T H'_1 \\ \sigma_1 \mathbf{e}_1 & H'_1 A_{22}^{(1)} H'_1 \end{bmatrix}$$


$$A^{(2)} = \begin{bmatrix} a_{11} & a_{12}^{(2)} & a_{13}^{(2)} & \cdots & a_{1n}^{(2)} \\ \sigma_1 & a_{22}^{(2)} & a_{23}^{(2)} & \cdots & a_{2n}^{(2)} \\ \hline 0 & a_{32}^{(2)} & a_{33}^{(2)} & \cdots & a_{3n}^{(2)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & a_{n2}^{(2)} & a_{n3}^{(2)} & \cdots & a_{nn}^{(2)} \end{bmatrix} \xrightarrow{H_2 = \begin{bmatrix} I_2 & \mathbf{0}^T \\ \mathbf{0} & H'_2 \end{bmatrix}} H_2 A^{(2)} H_2 = \begin{bmatrix} a_{11} & a_{12}^{(2)} & a_{13}^{(3)} & \cdots & a_{1n}^{(3)} \\ \sigma_1 & a_{22}^{(2)} & a_{23}^{(3)} & \cdots & a_{2n}^{(3)} \\ \hline 0 & \sigma_2 & a_{33}^{(3)} & \cdots & a_{3n}^{(3)} \\ 0 & 0 & \vdots & \ddots & \vdots \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & a_{n3}^{(3)} & \cdots & a_{nn}^{(3)} \end{bmatrix}$$

... ..

- 最终 $H_{n-2} \cdots H_1 A H_1 \cdots H_{n-2}$ 为上Hessenberg阵

实用的QR算法

- 实对称矩阵 A



- 带原点位移的QR迭代(改善收敛)

□ 单位移技术 $\begin{cases} Q_k R_k = A_k - s_k I, & \text{(作QR分解)} \\ A_{k+1} = R_k Q_k + s_k I, & k = 0, 1, 2, \dots \end{cases}$

$$A_{k+1} = R_k Q_k + s_k I$$


$$= Q_k^T (A_k - s_k I) Q_k + s_k I = Q_k^T A_k Q_k \longrightarrow \{A_k\} \text{ 仍两两正交相似}$$

□ 简单的Rayleigh策略: 取 $s_k = A_k(n, n)$, 加速收敛

□ 非对称阵有复特征值, 采用双位移

Matlab演示,

□ Matlab命令: **qr, eig, hess, schur, eigs** *eigsvdgui*



矩阵的奇异值分解

矩阵奇异值/奇异向量

■ $m \times n$ 实矩阵 A 的奇异值

(可看成非方阵的“特征值”)

定义5.12 $\begin{cases} Av = \sigma u \\ A^T u = \sigma v \end{cases}$ 非负实数 σ 为奇异值 (singular value)
非零向量 u, v 为左/右奇异向量 (singular vector)
 $\updownarrow$
 $u^T A = \sigma v^T$

□ 奇异向量乘以倍数仍满足. 一般考虑单位化的: $\|u\|_2 = \|v\|_2 = 1$

□ **Th5.23** 设 $m \geq n$, 矩阵 A 可以分解为 $A = U \Sigma V^T$, U, V 为正交阵, Σ 为对角阵, 其对角元 $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_n \geq 0$.

→ $AV = U\Sigma$, $Av_k = \sigma_k u_k$, $k = 1, \dots, n$ $\Sigma = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_n \end{bmatrix}$

□ 同时 $A^T = V \Sigma^T U^T$, $A^T U = V \Sigma^T$, $A^T u_k = \sigma_k v_k$

□ u_k/v_k 为左/右奇异向量 (能找到 n 对), 且 $\{u_k\}$ 和 $\{v_k\}$ 各自两两正交

□ 当 A 为实对称正定阵时, 奇异值分解 ~ 特征值分解?

奇异值分解(SVD)

“线性代数领域的瑞士军刀”

■ Th5.23 (奇异值分解定理)

- 矩阵 A 可以分解为 $A = U \Sigma V^T$, U, V 为正交阵, Σ 为对角阵, 其对角元 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n \geq 0$.
- 只需证明 $m \geq n$ 的情况

思路: $A^T A = V \Sigma^T \Sigma V^T = V \begin{bmatrix} \sigma_1^2 & & \\ & \ddots & \\ & & \sigma_n^2 \end{bmatrix} V^T$

$n \times n$

■ 证明

- $A^T A$ 对称半正定, 设非零特征值为 $\sigma_1^2, \sigma_2^2, \dots, \sigma_r^2$, 形成对角阵 Σ_r^2 (不妨设 $r < n$)

$$A^T A = \underbrace{[V_1 \ V_2]}_{\text{(正交阵)}} \begin{bmatrix} \Sigma_r^2 & O \\ O & O \end{bmatrix} \begin{bmatrix} V_1^T \\ V_2^T \end{bmatrix} \longrightarrow \begin{bmatrix} V_1^T \\ V_2^T \end{bmatrix} A^T A [V_1 \ V_2] = \begin{bmatrix} \Sigma_r^2 & O \\ O & O \end{bmatrix}$$

$$U_1^T U_1 = I_r \longleftarrow \Sigma_r^{-1} V_1^T A^T \boxed{A V_1 \Sigma_r^{-1}} = I_r \longleftarrow \begin{bmatrix} V_1^T A^T A V_1 & \dots \\ \dots & V_2^T A^T A V_2 \end{bmatrix}$$

$A V_2 = O$

奇异值分解(SVD)

■ 定理 (奇异值分解的存在性)

$$A = U \Sigma V^T$$

□ 证明 (续)

$$\begin{bmatrix} V_1^T \\ V_2^T \end{bmatrix} A^T A \begin{bmatrix} V_1 & V_2 \end{bmatrix} = \begin{bmatrix} \Sigma_r^2 & O \\ O & O \end{bmatrix} \Rightarrow \begin{matrix} A V_2 = O \\ \text{设 } U_1 = A V_1 \Sigma_r^{-1}, U_1^T U_1 = I_r \end{matrix}$$

U_1 为 $m \times r$ 列正交阵

根据 U_1 补齐正交单位向量得到正交阵 $U = \begin{bmatrix} U_1 & U_2 \end{bmatrix}$

$$U^T A V = \begin{bmatrix} U_1^T \\ U_2^T \end{bmatrix} A \begin{bmatrix} V_1 & V_2 \end{bmatrix} = \begin{bmatrix} U_1^T A V_1 & U_1^T A V_2 \\ U_2^T A V_1 & U_2^T A V_2 \end{bmatrix} = \begin{bmatrix} U_1^T A V_1 & O \\ U_2^T A V_1 & O \end{bmatrix}$$

$$U_1 = A V_1 \Sigma_r^{-1} \Rightarrow \begin{matrix} A V_1 = U_1 \Sigma_r \Rightarrow U_1^T A V_1 = \Sigma_r \\ U_2^T A V_1 = U_2^T U_1 \Sigma_r = O \end{matrix}$$

$$\text{所以, } U^T A V = \begin{bmatrix} \Sigma_r & O \\ O & O \end{bmatrix} = \Sigma$$

存在性得证!

且矩阵 Σ 是唯一确定的

奇异值分解(SVD)

Matlab: $[U, S, V] = \text{svd}(A);$
 $s = \text{svd}(A);$

■ 更多形式

$$A = U_{m \times m} \sum_{m \times n} V_{n \times n}^T =$$



□ 简化SVD分解

$$A = U_{m \times r} \sum_{r \times r} V_r^T$$

- 一般秩 r 不确定, $\leq \min(m, n)$
 简化SVD为 (以 $m > n$ 为例)

$$A = U_n \sum_n V^T \quad \rightarrow$$

$$A^T A = V \Sigma_n^2 V^T$$



`svd(A, 'econ')`

- 奇异值 σ_k 是 AA^T 或 $A^T A$ 的特征值的算术平方根
- 计算SVD: 对 $A^T A$ 用QR迭代算法(并不显式算 $A^T A$)
 (Gene Golub, 1965)




奇异值分解(SVD)

■ 奇异向量的意义

$$A = U \Sigma V^T \quad \begin{cases} AV = U\Sigma \\ A^T U = V\Sigma^T \end{cases}$$

$m \times m \quad m \times n \quad n \times n$

- 设 A 的秩为 r , $Av_1 = \sigma_1 u_1, \dots, Av_r = \sigma_r u_r, Av_{r+1} = 0, \dots, Av_n = 0$
- $A^T = V \Sigma U^T$, $A^T u_1 = \sigma_1 v_1, \dots, A^T u_r = \sigma_r v_r, A^T u_{r+1} = 0, \dots, A^T u_m = 0$
- 四个重要子空间的单位正交基



奇异值分解(SVD)

■ 奇异值与2-范数/F-范数

$$\|A\|_2 = \max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2} = \max_{x \neq 0} \frac{\|U \Sigma V^T x\|_2}{\|x\|_2} = \max_{x \neq 0} \frac{\|\Sigma V^T x\|_2}{\|V^T x\|_2} = \max_{y \neq 0} \frac{\|\Sigma y\|_2}{\|y\|_2} = \sigma_1$$

最大奇异值

若 A 非奇异方阵,
其奇异值均 > 0

$$\|A^{-1}\|_2 = \frac{1}{\sigma_n}$$

$$\text{cond}(A)_2 = \frac{\sigma_1}{\sigma_n}$$

奇异值的范围反映矩阵接近奇异的程度

□ SVD的向量外积和形式

$$A = \begin{bmatrix} u_1 & \cdots & u_m \end{bmatrix} \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_n \end{bmatrix} \begin{bmatrix} v_1^T \\ \vdots \\ v_n^T \end{bmatrix} = \begin{bmatrix} \sigma_1 u_1 & \cdots & \sigma_n u_n \end{bmatrix} \begin{bmatrix} v_1^T \\ \vdots \\ v_n^T \end{bmatrix} = \sum_{k=1}^n \sigma_k u_k v_k^T + \dots$$

Eckart-Young定理: 所有秩为 r 的矩阵中 A_r 最接近 A

$$A_r = \sum_{k=1}^r \sigma_k u_k v_k^T$$

$$\|A - A_r\|_2 = \sigma_{r+1} \quad \|A - A_r\|_F = \sqrt{\sum_{k=r+1}^{\min(m,n)} \sigma_k^2}$$